

基于改进 Elman 网的非线性系统的自适应建模与预估

赵英凯

蔡 宁

熊 辉

(南京化工大学 南京 210009)

(南京东方化工有限公司)

(南京化工大学)

摘 要 本文讨论了具有自适应功能的基于改进 Elman 网的动态系统辨识建模与在线预估方法。并依据生产过程的实测数据,利用该法建立了环己酮肟化投酮量的在线预估模型。该法对具有时变特性的非线性系统的建模与预估有一定的自适应功能。结果表明,按该法进行建模与预估,其自适应性与抗噪性有较大的改善。

关键词 Elman 网,递推最小二乘法(RLS),自适应建模与预估,环己酮,硝酸羟胺法(HPO)

1 引言

实际的工业对象常具有高度的非线性、关联性、时变性与不确定性。如何描述这种复杂工业过程的非线性动态特性就成了建模与预估的关键。前馈神经网络以其强有力的非线性映射能力在许多领域中获得了不少成功的应用。但由于前馈神经网络本质上是一种静态网络,只能实现非线性的静态映射,一般讲不具有动态信息处理能力。虽然许多学者在这方面做了许多工作^[1,2],以使用静态网络描述动态过程,如将动态时间建模问题化为静态的空间建模问题等,但这需要先验假定系统的 NARMA 模型类;需对模型结构进行定阶,特别是随系统阶次的增加或阶次未知,迅速扩大的网络结构,使网络学习收敛速度减慢,并造成网络输入节点过多、训练困难及对外部噪声敏感等弊病。

本文采用了改进的动态 Elman 网来建立预估模型。它是在前馈网络同层节点间引入互反馈与自反馈,使之具有很强的动态逼近能力^[3],可以用来描述任意非线性动态特性。为使之适应工况与操作条件的变化,加速网络的收敛过程,本文还对输出的线性组合层实施了递推最小二乘参数辨识,在线自适应调整输出层网络的权值与阈值,以此取代一般采用的重新进行样本的学习与模型的训练以适应对象时变的滚动修正法^[4]。对环己酮肟化投酮量的预估实验结果证明该方法是有效的,它具有适应时变特性与较强的抗噪能力。因此,在复杂过程的建模与预估中有着广阔的应用前景。

2 改进的 Elman 网络的结构与算法

2.1 网络结构

基本 Elman 网^[6]一般分为四层:输入层、隐层、结构层与输出层。其中输入层、隐层与输出层的连结类似于前馈网络,而其中的结构层由于能记忆隐层过去的状态,并在下一时刻连同网络输入一起作为隐层输入。因此 Elman 网具有动态记忆功能。这将有利于动态过程的建模与预估。其网络模型表达式如下所示:

$$h(k) = f[W^1 h_c(k) + W^2 u(k-1)] \quad (1)$$

$$h_c(k) = h(k-1) \quad (2)$$

$$y(k) = g[W^3 h(k)] \quad (3)$$

其中 $u(k-1) \in R^r$ 为输入向量, $h(k) \in R^n$ 为隐层输出, $h_c(k) \in R^n$ 为结构层输出, $y(k) \in R^m$ 为输出层输出; W^1, W^2, W^3 分别为结构层至隐层、输入层至隐层、隐层至输出层的连接权矩阵; $f(\cdot)$ 与 $g(\cdot)$ 分别为隐层单元与输出单元的激励函数所组成的非线性向量函数。此处取 $f(\cdot)$ 为 Sigmoid 函数, 即 $f(z) = \frac{1}{1 + \exp(-z)}$, $g(\cdot)$ 为隐层输出的线性组合 (阈值为 γ)。

由于基本的 Elman 网利用标准 BP 算法, 仅能辨识一阶动态系统^[6], 为此可在算法上或网络结构上对其加以改进。如将基本 Elman 网的结构单元中引入一固定增益 α 的自反馈连接, 得到改进的 Elman 网, 如图 1 所示。




图 1 改进的 Elman 网结构图

具体网络模型表达式如下: ($m = 1$ 时)

$$h(k) = f[W^1 h_c(k) + W^2 u(k-1)] \quad (4)$$

$$h_c(k) = h(k-1) + \alpha h_c(k-1) \quad (5)$$

$$y(k) = W^3 h(k) + \gamma \quad (6)$$

显然 $\alpha = 0$ 时, 改进的 Elman 网便退化为基本 Elman 网。

2.2 学习算法

由于对结构单元增加了自反馈连接, 故改进的 Elman 网可利用标准 BP 学习算法辨识高阶动态系统。具体推导请见文献^[6], 得算法如下:

$$\Delta W_j^1 = \eta \delta_o^o h_j(k) \quad \text{其中: } j = 1, 2, \dots, n \quad (7)$$

$$\Delta W_{jn}^3 = \eta \delta_j^1 u_q(k-1) \quad \text{其中: } j = 1, 2, \dots, n; q = 1, 2, \dots, \gamma \quad (8)$$

$$\Delta W_{jl}^1 = \eta \delta_o^o W_j^3 \frac{\partial h_j(k)}{\partial W_{jl}^1} \quad \text{其中: } j = 1, 2, \dots, n; l = 1, 2, \dots, n \quad (9)$$

$$\frac{\partial h_j(k)}{\partial W_{jl}^1} = f'_j(\cdot) h_l(k-1) + \alpha \frac{\partial h_j(k-1)}{\partial W_{jl}^1} \quad (10)$$

式中 η 为学习率, 它可自适应调整^[7], 如 $\eta(k+1) = \eta(k) \frac{E(k-1)}{E(k)}$,

$\delta_o = y_d(k) - y(k)$, y_d 为实际 (期望) 输出,

$$\delta_j^1 = \delta_o^o W_j^3 f'_j(\cdot)$$

为简单起见,取 α 为常数 (如取为 0.05)。

3 采用 RLS 法对网络输出层进行在线校正

实践证明,上述模型长期在线运行于一时变对象,其模型精度与预估值都不能令人满意。因为实际工业对象通常是十分复杂的生产过程,操作条件变化大,故需对网络模型进行自适应调整。而一般采用的当偏差大到一定程度时,便终止原预估模型的使用,强迫计算机利用新的数据样本离线重新学习与训练,这本质上不是一种在线修正,且收敛速度慢,实时性差。

由以上 Elman 网结构可知,网络输出层有如下形式:

$$y_d(k) = y(k) + e(k) - \sum_{j=1}^n W_j^3 h_j(k) + \gamma + e(k) \quad (11)$$

当运行条件变化时,可采用线性系统在线参数辨识算法对权值 W_j^3 与阈值进行适当调整,使 Elman 网具有自适应功能,这样最终预估值也能适应变化的条件。

若令 $x^T(k) = [h_1(k), h_2(k), \dots, h_n(k), 1]$

$$\theta^T(k) = [W_1^3(k), W_2^3(k), \dots, W_n^3(k), \gamma]$$

则由(11)式得

$$y(k) = x^T(k)\theta(k) + e(k) \quad (12)$$

根据递推最小二乘算法,得以下递推算式:

$$\hat{\theta}(k+1) = \hat{\theta}(k) + K(k+1)[y(k) + X^T\hat{\theta}(k)] \quad (13)$$

$$K(k+1) = P(k)x(k+1)[x^T(k+1)P(k)x(k+1)]^{-1} \quad (14)$$

$$P(k+1) = [I - K(k+1)x^T(k+1)]P(k) \quad (15)$$

由此可在线递推出 W_j^3 与 γ 的估计值,使原 Elman 网预估模型具有一定的自适应能力。

4 环己酮肟化投酮量的建模与在线预估

大多数己内酰胺生产都要经过环己酮肟这个中间产物。而环己酮肟是由磷酸羟胺与环己酮的逆流等摩尔接触在肟化反应器中反应生成的。影响肟化反应的主要因素为肟化反应温度、反应终点 pH 值、反应接触面、搅拌速率与配料比,特别是环己酮与羟胺的配料比不仅影响到原料的消耗,还影响到环己酮的质量。而磷酸羟胺的制备与催化剂的活性、羟胺反应器的压力、温度、压降以及磷酸缓冲母液中各离子浓度有密切关系。因此利用常规方法或遵循现代控制理论途径去寻求较佳的选择性、羟胺效率与触媒活性,特别是根据已制备的磷酸羟胺去估计较佳的肟化投酮量是很困难的。

为此,可利用以上神经网络模型与相应的自适应算法,针对肟化反应器这一严重非线性、强时变特性的复杂 MISO 系统,进行系统建模与环己酮的在线预估。

为寻求与肟化投酮量相关性较大的输入变量,可采用逐步回归分析法^[8]确定相关量。此处根据现场专家提供的经验与知识,初步确定以下 13 个量作为该复杂化工对象的输入,它们分别是:

- | | |
|------------------------------------|----------|
| $u_1(k)$ — 磷酸缓冲母液中的 H^+ 浓度 | (mmol/g) |
| $u_2(k)$ — 磷酸缓冲母液中的 NH_3OH^+ 浓度 | (mmol/g) |
| $u_3(k)$ — 磷酸缓冲母液中的 $H_2PO_4^-$ 浓度 | (mmol/g) |
| $u_4(k)$ — 磷酸缓冲母液中的 NH_4^+ 浓度 | (mmol/g) |

$u_5(k)$ —磷酸缓冲母液中的 NO_3^- 浓度	(mmol/g)
$u_6(k)$ —磷酸缓冲母液中的游离 H^+ 浓度	(mmol/g)
$u_7(k)$ —循环气 H_2 含量(由在线分析仪连续测取)	(%)
$u_8(k)$ —I. P. L 进料量(磷酸缓冲母液流量)	(m^3/h)
$u_9(k)$ —羟胺反应器压力	(kPa)
$u_{10}(k)$ —羟胺反应器温度	($^{\circ}\text{C}$)
$u_{11}(k)$ —循环气流量	(kNm^3/h)
$u_{12}(k)$ —羟胺反应器压降	(kPa)
$u_{13}(k)$ —高位槽液位	(%)

而对象的输出为

Y_{11} —脌化投酮量 (m^3/h)

利用现场大量实测数据,并经归一化处理,对网络拓扑结构为 13—9(9)—1 的普通 Elman 网与自适应 Elman 网分别进行了离线学习训练(迭代次数为 500 次),从而得到该复杂对象的神网模型,再利用该模型分别对 23 与 27 批样本进行测试,结果如表 1、表 2 与图 2、图 3 所示。

表 1 基于 y_{11} 改进的 Elman 网实验结果

输入量:	13
隐层数:	9
批量数:	23
α_1 :	0.06
η_1 :	0.05
测量值	预测值
0.819209	0.830922
0.805085	0.839689
0.800847	0.830464
0.807910	0.817060
0.800847	0.830122
0.800847	0.799964
0.884181	0.880529
0.918079	0.866023
0.911017	0.900087
0.944915	0.892884
0.923729	0.938234
0.966102	0.945076
0.951977	0.949023
0.911017	0.953278
0.963277	0.947193
0.978814	0.986354
0.978079	0.951232
0.960452	0.950197
0.978814	0.946647
0.978814	0.956756
0.935029	0.946541
0.966102	0.933140
1.000000	0.954831

表 2 基于 y_{11} 自适应 Elman 网实验结果

输入量:	13
隐层数:	9
批量数:	27
α_1 :	0.06
η_1 :	0.05
测量值	预测值
0.961905	0.978835
1.000000	0.96084
0.957143	0.960527
0.985714	0.960353
0.971429	0.959175
0.928572	0.959647
0.980952	0.960822
0.985714	0.958976
0.976191	0.966541
0.947619	0.956962
0.942857	0.961541
0.947619	0.958138
0.933333	0.933551
0.928572	0.949284
0.971429	0.950147
0.976191	0.951977
0.980952	0.955601
0.933333	0.946531
0.980952	0.946017
0.933333	0.927509
0.947619	0.949037
0.947619	0.950183
0.923810	0.936991
0.933333	0.925876
0.952381	0.952206
0.947619	0.956566
0.933333	0.952016

实验中,我们还研究了以上网络模型的抗噪能力。先将用于建模的输入加入白噪声,用带噪声数据去训练网络,再用训练好的网络预测 27 批输出。观察基于改进的 Elman 网与有




图2 改进的 Elman 网实验结果




图3 自适应 Elman 网实验结果

自适应功能的改进 Elman 网两种情况下预测误差 $E = \frac{\sum_{k=1}^N [y_d(k) - y(k)]^2}{N}$ 对信噪比的变化曲线(如图 4 所示)可知;后者的抗噪能力明显高于前者。从表 3 和图 4 中也可看出,对带




图4 y_{11} 对比实验结果

表3 y_{11} 对比实验结果 (error * 100)

信噪比	0.03	0.07	0.10	0.13	0.17	0.20	0.23	0.27	0.30	0.33	0.50	0.67	0.83	1.00
ELMAN	1.272	1.274	1.276	1.261	1.276	1.276	1.277	1.276	1.278	1.275	1.320	1.334	1.352	1.361
ELMAN+自适应	0.446	0.603	0.784	0.905	0.948	0.983	0.978	0.990	0.960	0.967	0.948	0.971	0.995	1.001

有自适应的改进 Elman 网,当信噪比 <0.13 时,网络的预测精度几乎未受影响。这说明,其抗噪能力较强。

5 结论

本文讨论了基于改进 Elman 网的动态系统的建模与预估,并利用 RLS 法对网络输出层进行了在线校正。对卧化投酮量的预估实验证明,该方法在时变非线性系统的建模与预估中有较高的精度与自适应能力,且抗噪能力较强。经改进与集成,可以作为开发复杂系统状态预估与优化的先进控制算法而加以实施。

参考文献

- [1] Frasconi P, Gori M, Soda G, Local Feedback Multi-layered Networks, Neural Computation, 1992, 4; PP. 120-130.
- [2] Alexander G P, Amir F A, Dynamic Gradient Descent Learning Algorithms for Enhanced Empirical Modeling of

Power Plants, Nuclear Technology, 1994, 125(2); PP. 178—179.

[3] Funahashi K, Nakamura Y, Approximation of Dynamical System by Continuous Time Recurrent Neural Networks, Neural Network, 1993 6; PP. 801—806.

[4] 赵英凯, 蔡宁, 基于对角递归神经网络的时化投影量的在线预估, 1998年中国智能自动化学术会议论文集, 上册, PP. 279—282, 1998, 5, 上海.

[5] Gao X Z, Gao X M, Ovaska S J, A Modified Elman Neural Network Model with Application to Dynamical System Identification, in 1996 IEEE International Conference on Systems, Man and Cybernetics, Beijing, 1996, PP. 1376—1381.

[6] 孙增圻, 张再兴, 邓志东, 智能控制理论与技术, 清华大学出版社, 1997, 北京.

[7] 杜坚, 何永保, 动态批处理方式加速BP网络的收敛性, 中国神经网络首届学术大会, 上册, 1990年, PP. 263—269.

[8] 白新桂, 数据分析与实验优化设计, 清华大学出版社, 1998年, 北京.

[9] 曹劲, 王桂增, 基于自校正回归神经元网络的预报建模, 信息与控制, 1998, 27(2), PP. 156—160.

赵英凯 男 宣主任 教授

1945年8月12生于重庆市, 1968年7月毕业于南京大学物理系物理专业.

现任中国自动化学会智能自动化专业委员会委员

目前正在从事研究生及本科生的教学、指导工作, 同时进行了一项国家自然科学基金课题与两项与工厂合作课题的研究工作, 主要研究领域为现代控制理论及应用, 智能自动化及应用, 以及计算机控制技术

出版专著: 1. 系统辨识概述, 南京化工大学出版社, 1983年

2. 微机过程控制, 南京化工大学出版社, 1985年

已发表学术论文36篇

通信地址: 210009 南京化工大学自动化及计算机系

电话: (025)3316755—3602